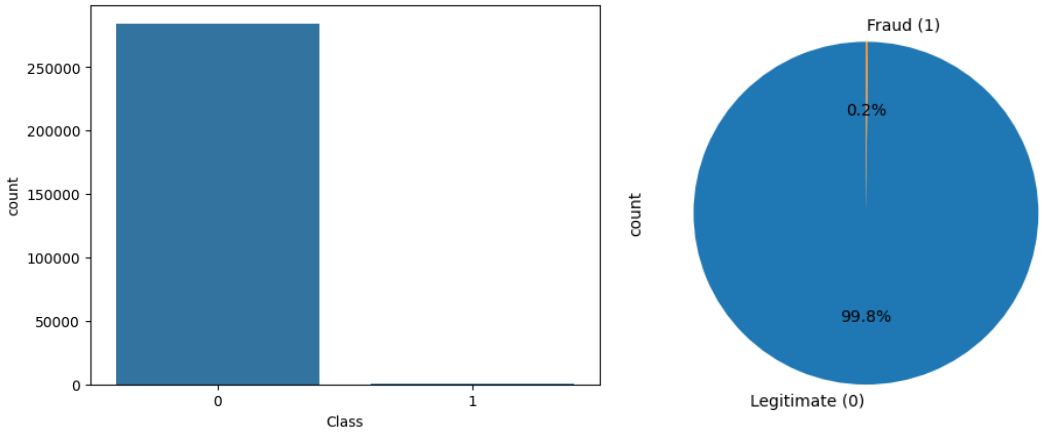
LAPORAN PRAKTIKUM 3 - ENSEMBLE LEARNING

Jonathan Joyo Wibowo
5054251026

1. Dataset

Dataset diperoleh dari https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud
Dataset tersebut berisi transaksi-transaksi pada berbagai atm di Eropa, tugas kita adalah untuk mengklasifikasikan apakah suatu transaksi adalah normal atau tindak penipuan

2. Distribusi Label Class

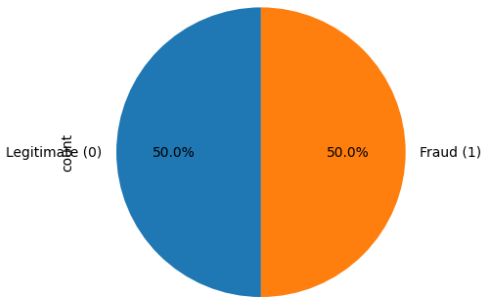


Distribusi Class pada dataset adalah 284315 untuk label 0 (transaksi normal), dan 492 untuk label 1 (penipuan)
Disini, dataset sangat imbalance, maka dari itu akan dilakukan sesuatu untuk menangani hal ini

3. Penanganan Imbalance

Untuk menangani data imbalance, kita akan melakukan oversampling dengan metode SMOTE
SMOTE sendiri bekerja dengan cara membuat data sintetis baru diantara data-data minoritas sehingga jumlahnya sama dengan data mayoritas. Jadi setelah diberlakukan SMOTE, distribusi dari label Class seharusnya seimbang atau 50% untuk setiap label

Distribusi label Class setelah oversampling:

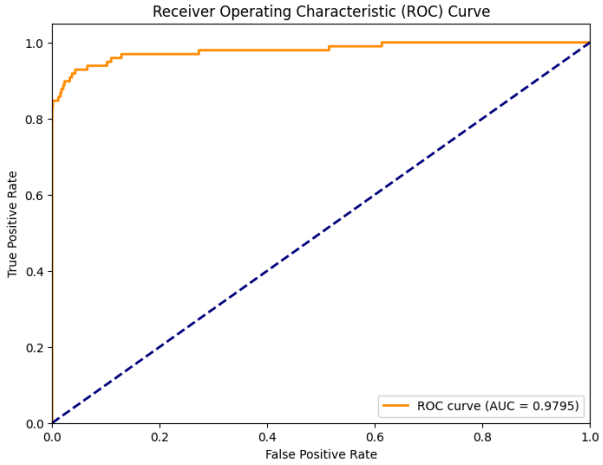


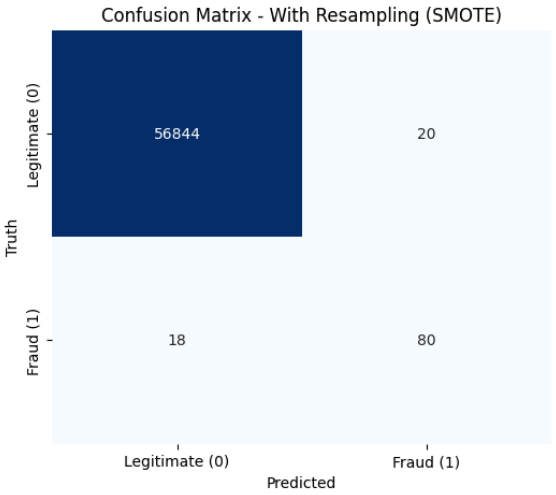
4. Modelling

Untuk Modelling, kita menggunakan XGBoost, salah satu model ensemble learning yang populer. Kita juga melatih model yang sama dengan 2 dataset yang berbeda, satu dengan dataset tanpa oversampling, satu dengan dataset dengan oversampling.

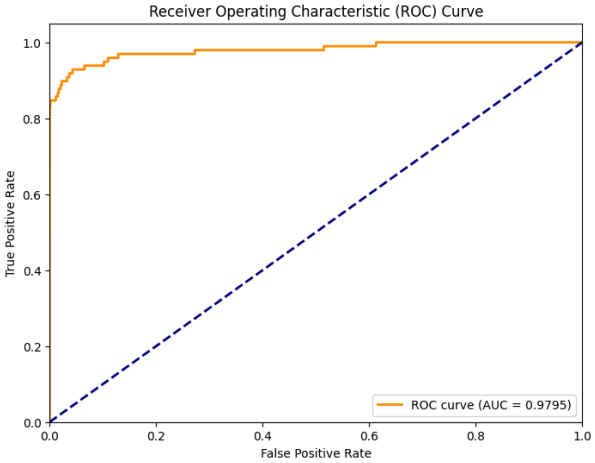
5. Evaluasi

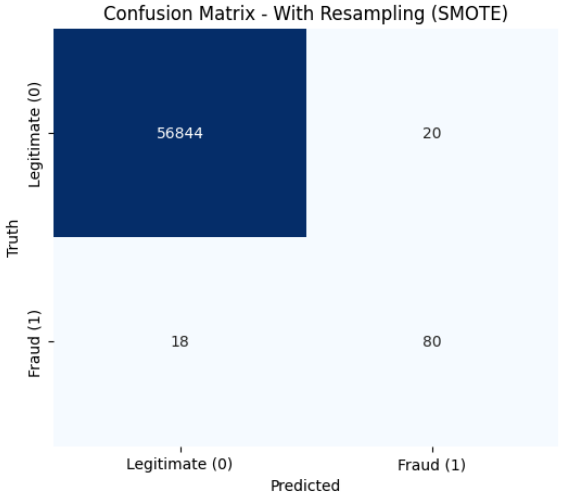
Hasil tanpa resampling:





Hasil dengan resampling:





Perbandingan Metric kedua model:

	accuracy	precision	recall	f1
no_resampling	0.999403	0.932432	0.704082	0.802326
resampling	0.999333	0.800000	0.816327	0.808081

Setiap model memiliki akurasi yang sangat tinggi karena imbalance pada dataset tadi, maka dari itu, kita disini menggunakan metric f1 score dan roc curve yang tidak hanya menilai akurasi

Disini bisa kita lihat bahwa, model yang menggunakan data dengan resampling memiliki hasil yang lebih bagus dari pada yang tidak menerapkan resampling sama sekali, ini karena resampling data minoritas mengeliminasi bias yang dimiliki model terhadap dataset mayoritas, jadi model akan memprioritaskan kedua class dengan seimbang