

LAPORAN PRAKTIKUM

Tugas Praktikum 2: Praproses Data

Dataset House Prices: Advanced Regression Techniques

Nama	Jonathan Joyo Wibowo
NRP	5054251026
Tanggal	September 2026

Daftar Isi

1	Pendahuluan	2
1.1	Tujuan	2
1.2	Dataset	2
2	Pembersihan Data	2
2.1	Pemeriksaan nilai hilang	2
2.2	Penanganan nilai hilang (imputasi)	3
3	Deteksi dan Penanganan Outlier	3
3.1	Deteksi dengan boxplot	3
3.2	Keputusan: outlier disesuaikan, tidak dihapus	4
3.3	Hasil	4
4	Transformasi Data	6
4.1	Encoding kategoris (one-hot)	6
4.2	Standarisasi	6
5	Reduksi Dimensi	6
5.1	Analisis korelasi	6
5.2	Principal Component Analysis (PCA)	7
6	Ringkasan Dataset Akhir	9
7	Kesimpulan	9
7.1	Catatan dan keterbatasan	9

1 Pendahuluan

Praproses data adalah tahap yang menentukan kualitas hasil analisis maupun model *machine learning*. Data mentah umumnya mengandung nilai hilang, pencilan (*outlier*), skala atribut yang berbeda-beda, serta atribut kategoris yang belum bisa diolah langsung oleh algoritma. Praktikum ini menerapkan rangkaian praproses pada dataset harga rumah di Ames, Iowa, mulai dari pembersihan data, transformasi, sampai reduksi dimensi.

1.1 Tujuan

1. Menerapkan langkah praproses: pembersihan, transformasi, dan reduksi data.
2. Meningkatkan kualitas data dengan menangani nilai hilang dan data yang tidak konsisten.
3. Menerapkan normalisasi/standarisasi dan *one-hot encoding*.

1.2 Dataset


Dataset yang digunakan adalah `train.csv` dari kompetisi Kaggle *House Prices: Advanced Regression Techniques*. Berkas ini berisi 1460 baris dan 81 kolom: satu kolom `Id`, 79 atribut penjelas (ukuran, tahun dibangun, kualitas, lokasi, dan sebagainya), serta satu variabel target `SalePrice`. Terdapat 38 kolom numerik (termasuk `Id` dan `SalePrice`) dan 43 kolom bertipe objek/kategoris. Pemrosesan dilakukan dengan Python (pandas, NumPy, scikit-learn, seaborn, dan matplotlib) di Google Colab.

2 Pembersihan Data

2.1 Pemeriksaan nilai hilang

Pemeriksaan dengan `data.isna().sum()` menunjukkan bahwa 19 dari 81 atribut memiliki nilai hilang, dengan total 7.829 sel kosong. Lima atribut memiliki proporsi nilai hilang di atas 50% sehingga dibuang, sesuai ketentuan tugas. Proporsi nilai hilang per atribut ditampilkan pada Gambar 1.

```
missing_pct = data.isna().sum() / len(data)
cols_to_drop = missing_pct[missing_pct > 0.5].index.tolist()
data = data.drop(columns=cols_to_drop)
```



Gambar 1: Proporsi nilai hilang per atribut. Batang merah adalah atribut dengan proporsi di atas 50% (garis putus-putus) yang dihapus.

Atribut dihapus	Hilang	Arti nilai kosong pada data
PoolQC	99,5%	Rumah tidak memiliki kolam renang
MiscFeature	96,3%	Tidak ada fitur tambahan
Alley	93,8%	Tidak ada akses gang
Fence	80,8%	Tidak ada pagar
MasVnrType	59,7%	Jenis veneer dinding tidak tercatat

Tabel 1: Atribut dengan nilai hilang lebih dari 50% yang dihapus. Dimensi data berubah dari 81 menjadi 76 kolom.

Atribut FireplaceQu (47,3%) tidak dihapus karena masih di bawah ambang 50%.

2.2 Penanganan nilai hilang (imputasi)

Sisa 14 atribut yang masih memiliki nilai hilang diimputasi menggunakan SimpleImputer dengan strategi yang disesuaikan dengan tipe data:

- **Atribut numerik** (LotFrontage, MasVnrArea, GarageYrBlt) diisi dengan **median**. Median dipilih karena tidak terpengaruh oleh nilai ekstrem, sedangkan atribut seperti LotFrontage dan MasVnrArea cenderung miring ke kanan.
- **Atribut kategoris** (BsmtQual, BsmtCond, BsmtExposure, BsmtFinType1, BsmtFinType2, Electrical, FireplaceQu, GarageType, GarageFinish, GarageQual, GarageCond) diisi dengan **modus** (nilai yang paling sering muncul).


```
num_imputer = SimpleImputer(strategy="median")
obj_imputer = SimpleImputer(strategy="most_frequent")
data[cols_num_missing] = num_imputer.fit_transform(data[cols_num_missing])
data[cols_obj_missing] = obj_imputer.fit_transform(data[cols_obj_missing])
```

Hasil: setelah imputasi, `data.isna().sum()` bernilai 0 untuk seluruh 76 kolom, sehingga tidak ada lagi nilai hilang.

3 Deteksi dan Penanganan Outlier

3.1 Deteksi dengan boxplot

Boxplot dibuat untuk seluruh 37 atribut numerik (tidak termasuk Id), dan histogram distribusinya dibuat sebagai pembanding. Gambar 2 menampilkan sebagian atribut yang representatif. Dengan aturan IQR (nilai di luar $Q_1 - 1,5 \cdot IQR$ dan $Q_3 + 1,5 \cdot IQR$), sejumlah atribut memiliki banyak titik pencilan, misalnya EnclosedPorch (208 titik), BsmtFinSF2 (167), OverallCond (125), ScreenPorch (116), dan OpenPorchSF (77).



Gambar 2: Boxplot sebagian atribut numerik sebelum penanganan outlier. Atribut luas teras dan kolam memiliki banyak nilai jauh di atas kotak.

3.2 Keputusan: outlier disesuaikan, tidak dihapus

Outlier **tidak dihapus**, melainkan disesuaikan melalui transformasi. Alasannya:


1. Nilai ekstrem pada data ini umumnya bukan kesalahan input, tetapi rumah yang benar-benar berbeda, misalnya rumah besar dengan teras luas. Nilai tersebut membawa informasi yang relevan bagi harga.
2. Banyak atribut luas area (teras, kolam) bernilai 0 untuk sebagian besar rumah karena rumah tersebut memang tidak memilikinya. Titik di luar “kotak” pada boxplot lalu sebenarnya adalah rumah yang memiliki fasilitas itu, bukan data yang salah.
3. Dengan hanya 1460 baris, menghapus ratusan baris akan mengurangi data secara signifikan dan berisiko membuat hasil bias.

Penyesuaian dilakukan dengan transformasi $\log(1 + x)$ (`np.log1p`) pada enam atribut luas yang sangat miring ke kanan. Transformasi ini mengecilkan pengaruh nilai besar dan aman untuk nilai 0.


```
porch_cols = ['WoodDeckSF', 'OpenPorchSF', 'EnclosedPorch',
              '3SsnPorch', 'ScreenPorch', 'PoolArea']
for col in porch_cols:
    data[col] = np.log1p(data[col])
```

3.3 Hasil

Gambar 3 dan Gambar 4 membandingkan distribusi keenam atribut sebelum dan sesudah transformasi, sedangkan Tabel 2 merangkum perubahan kemiringan (*skewness*).



Gambar 3: Distribusi enam atribut luas sebelum transformasi (sangat miring ke kanan).



Gambar 4: Distribusi enam atribut yang sama setelah transformasi $\log(1+x)$.

Atribut	Skewness sebelum	Skewness sesudah
WoodDeckSF	1,54	0,15
OpenPorchSF	2,36	-0,02
EnclosedPorch	3,09	2,11
ScreenPorch	4,12	3,15
3SsnPorch	10,30	7,73
PoolArea	14,83	14,36

Tabel 2: Perubahan kemiringan distribusi akibat transformasi $\log(1+x)$.

Transformasi sangat efektif untuk WoodDeckSF dan OpenPorchSF, yang menjadi hampir simetris. Untuk EnclosedPorch, ScreenPorch, 3SsnPorch, dan PoolArea, kemiringan berkurang tetapi masih tinggi. Sebabnya, mayoritas nilainya adalah 0 sehingga setelah transformasi tetap terbentuk lonjakan besar di nol yang tidak bisa dihilangkan oleh transformasi apa pun. Atribut ini sebaiknya dipertimbangkan sebagai indikator “ada/tidak ada” pada tahap analisis lanjutan.

4 Transformasi Data

4.1 Encoding kategoris (one-hot)

Sebanyak 38 atribut kategoris (setelah 5 atribut dihapus) diubah menjadi variabel biner dengan `OneHotEncoder(handle_unknown="ignore")`. Setiap kategori menjadi satu kolom baru berawalan nama atributnya, misalnya `Neighborhood_CollgCr` atau `ExterQual_Gd`. Encoding ini menghasilkan 235 kolom biner. Kolom kategoris asli dibuang, sehingga dimensi data menjadi 1460 baris dan 273 kolom (termasuk `Id` dan `SalePrice`).

```
encoder = OneHotEncoder(sparse_output=False, handle_unknown="ignore")
encoded = encoder.fit_transform(data[cols_obj])
encoded_df = pd.DataFrame(encoded, columns=encoder.get_feature_names_out(cols_obj),
                          index=data.index)
data = pd.concat([data.drop(columns=cols_obj), encoded_df], axis=1)
```

4.2 Standarisasi

Variabel target `SalePrice` dipisahkan dari fitur (`x_data`, 272 kolom), kemudian seluruh fitur distandarisasi dengan `StandardScaler` (*z-score*): $z = \frac{x - \mu}{\sigma}$. Standarisasi dipilih (bukan *min-max*) karena tahap berikutnya, PCA, sensitif terhadap varians tiap atribut dan bekerja paling baik ketika semua fitur berpusat di nol dengan simpangan baku 1. Standarisasi juga tidak terlalu terpengaruh oleh pencilan yang masih tersisa.

```
x_data, y_data = data.drop(columns=["SalePrice"]), data["SalePrice"]
x_data = StandardScaler().fit_transform(x_data)
```

Hasil: seluruh fitur memiliki rata-rata mendekati 0 (galat maksimum sekitar 4×10^{-14}) dan simpangan baku sekitar 1. Target `SalePrice` sengaja tidak distandarisasi agar tetap dalam satuan aslinya.

5 Reduksi Dimensi

5.1 Analisis korelasi

Karena hasil one-hot encoding menghasilkan banyak kolom yang saling terkait, dihitung matriks korelasi mutlak antarfitur, dan satu dari setiap pasangan dengan korelasi di atas **0,85** dibuang. Untuk setiap pasangan, kolom yang dibuang adalah kolom yang muncul belakangan pada matriks segitiga atas.


```
corr_matrix = x_data.corr().abs()
upper = corr_matrix.where(np.triu(np.ones(corr_matrix.shape), k=1).astype(bool))
to_drop = [c for c in upper.columns if any(upper[c] > 0.85)]
x_data_reduced = x_data.drop(columns=to_drop)
```

Ada 20 fitur yang dibuang sehingga fitur berkurang dari 272 menjadi 252. Pasangan berkorelasi tertinggi ditampilkan pada Tabel 3.

Fitur 1	Fitur 2 (dibuang)	r
Utilities_AllPub	Utilities_NoSeWa	1,00
CentralAir_N	CentralAir_Y	1,00
Street_Grvl	Street_Pave	1,00
Exterior1st_CBlock	Exterior2nd_CBlock	1,00
SaleType_New	SaleCondition_Partial	0,99
Exterior1st_VinylSd	Exterior2nd_VinylSd	0,98
RoofStyle_Gable	RoofStyle_Hip	0,93
LotShape_IR1	LotShape_Reg	0,93

Tabel 3: Contoh pasangan fitur dengan korelasi di atas 0,85.

Sebagian besar fitur yang dibuang adalah kolom hasil one-hot encoding. Alasannya ada dua. Pertama, kategori biner seperti CentralAir (Y/N) menghasilkan dua kolom yang saling berkebalikan sempurna. Kedua, atribut yang memang berhubungan, misalnya Exterior1st dan Exterior2nd, menghasilkan kolom yang hampir identik. Satu-satunya atribut numerik asli yang dibuang adalah GarageArea, karena sangat berkorelasi dengan GarageCars (keduanya sama-sama mengukur kapasitas garasi).




Gambar 5: Peta panas korelasi 14 atribut numerik yang paling berkorelasi dengan SalePrice. GarageCars dengan GarageArea serta GrLivArea dengan TotRmsAbvGrd terlihat saling berkorelasi kuat.

5.2 Principal Component Analysis (PCA)


PCA diterapkan pada 252 fitur hasil seleksi korelasi dengan syarat mempertahankan minimal 90% varians total data.

```
pca = PCA(n_components=0.9)
x_pca = pca.fit_transform(x_data_reduced)
x_pca.shape # (1460, 146)
```

Hasilnya, data direduksi menjadi **146 komponen utama** yang menjelaskan 90,14% varians. Komponen pertama menjelaskan 6,19% dan komponen kedua 2,94% varians, sehingga informasi tersebar merata di banyak komponen (Gambar 6). Hal ini wajar karena mayoritas fitur adalah kolom biner hasil one-hot yang relatif independen satu sama lain. Untuk mencapai 95% varians dibutuhkan 171 komponen.



Gambar 6: Scree plot 30 komponen pertama (kiri) dan varians kumulatif (kanan). Garis merah menandai 90% varians, garis hijau menandai 146 komponen.



Gambar 7: Proyeksi data pada dua komponen utama pertama, diwarnai dengan logaritma SalePrice.

6 Ringkasan Dataset Akhir

Tahap	Proses	Dimensi
Awal	Data mentah <code>train.csv</code>	1460 × 81
Pembersihan	Hapus 5 kolom dengan nilai hilang lebih dari 50%, imputasi median/modus	1460 × 76
Outlier	Transformasi $\log(1 + x)$ pada 6 atribut	1460 × 76
Encoding	One-hot pada 38 atribut kategoris (+235 kolom)	1460 × 273
Standarisasi	StandardScaler pada 272 fitur (target dipisah)	1460 × 272
Korelasi	Buang 20 fitur dengan korelasi lebih dari 0,85	1460 × 252
PCA	Pertahankan 90% varians	1460 × 146

Tabel 4: Ringkasan perubahan dimensi data pada setiap tahap praproses.

Dataset akhir terdiri dari 1460 baris dengan 146 komponen utama (PC1 sampai PC146) ditambah kolom target `SalePrice`, yaitu 147 kolom. Dataset tidak memiliki nilai hilang, seluruh atribut berskala seragam dan bertipe numerik, serta dimensinya turun dari 81 kolom awal (272 fitur setelah encoding) menjadi 146 komponen. Dataset ini disimpan sebagai berkas `.csv` untuk dikumpulkan.

7 Kesimpulan

1. Praproses mengubah data mentah yang mengandung 7.829 sel kosong menjadi dataset bersih tanpa nilai hilang. Lima atribut dengan kekosongan di atas 50% dibuang, sisanya diimputasi dengan median (numerik) atau modus (kategoris).
2. Outlier dipertahankan dan disesuaikan dengan transformasi $\log(1 + x)$ karena mewakili rumah yang benar-benar berbeda. Transformasi ini sangat efektif pada `WoodDeckSF` dan `OpenPorchSF`, tetapi kurang efektif pada atribut dengan mayoritas nilai nol.
3. One-hot encoding dan standarisasi membuat seluruh atribut numerik dengan skala seragam, sehingga siap dipakai oleh PCA dan algoritma berbasis jarak atau gradien.
4. Seleksi korelasi membuang 20 fitur redundan, dan PCA merangkum 252 fitur menjadi 146 komponen dengan 90,14% varians terjaga.

7.1 Catatan dan keterbatasan

- Atribut `Id` tidak dibuang dari fitur sehingga ikut terstandarisasi dan masuk ke PCA. Karena `Id` hanyalah nomor urut, sebaiknya dikeluarkan pada iterasi berikutnya.
- Nilai kosong pada `Alley`, `PoolQC`, `Fence`, dan `MiscFeature` sebenarnya bermakna “tidak ada fasilitas” sehingga menghapus kolom tersebut berarti kehilangan informasi. Pilihan ini mengikuti ketentuan tugas (ambang 50%).
- Imputasi, standarisasi, dan PCA dilakukan pada seluruh data sebelum pembagian data latih dan uji. Jika dataset ini dipakai untuk pemodelan, tahapan tersebut sebaiknya di-*fit* hanya pada data latih untuk menghindari kebocoran data (*data leakage*).
- Komponen utama sulit diinterpretasikan secara langsung. Jika interpretabilitas penting, seleksi fitur (tanpa PCA) dapat menjadi alternatif.