

Laporan Praktek Penambangan Data

Jonathan Joyo Wibowo
5054251026

1.1 Pengambilan Data

Data diambil dari yahoo finance melalui endpoint berikut, di sini saya menggunakan data index saham S&P 500, dengan timeframe 1 hari, data yang diambil adalah dari 20 tahun terakhir

Endpoint: <https://query1.finance.yahoo.com/v8/finance/chart/SPY?range=20y&interval=1d>

1.2 Isi Data

Data memiliki beberapa fitur, yaitu timestamp, open, high, low, close, adjusted close, dan volume

timestamp: data **interval** yang berisi informasi tentang waktu

open: data **rasio** yang berisi informasi harga diawal hari itu

high: data **rasio** yang berisi informasi harga tertinggi pada hari itu

low: data **rasio** yang berisi informasi harga terendah pada hari itu

close: data **rasio** yang berisi informasi harga diakhir hari itu

2.1 Preprocessing Data

Sebelum data diproses lebih lanjut, saya menyesuaikan nilai Open, High, Low, Close, dan Volume menggunakan faktor pembagi dari Adjusted Close untuk mengantisipasi pengaruh *stock split* maupun pembagian dividen sepanjang periode 20 tahun

Saya juga mengubah timestamp menjadi format yang mudah dibaca oleh manusia (YYYY-MM-DD)

2.2 Feature Engineering

Dari fitur-fitur yang ada, saya membentuk fitur-fitur yang baru yang pada akhirnya akan diberlakukan EDA (*Exploratory Data Analysis*)

high_low_spread: high_low_spread: Mengukur volatilitas harian, semakin tinggi nilainya, semakin volatil harga

close_open_spread: Persentase perubahan harga dari open ke close pada hari yang sama

volume_change: Persentase perubahan volume harian dibanding hari sebelumnya

dist_sma_200: Jarak harga saat ini terhadap Indikator SMA 200 (*Simple Moving Average 200*) / rata-rata 200 hari. Jika positif, maka trend sedang naik, jika negatif, maka trend sedang turun

rsi_14: Indikator RSI (Relative Strength Index) 14 hari (skala 0–100). jika >70 maka saham dalam keadaan overpriced / overbought, jika <30 maka saham dalam keadaan underpriced / oversold, selain itu maka saham dalam keadaan netral


return_1d: Persentase perubahan harga dalam sehari terakhir

return_30d: Persentase perubahan harga dalam 30 hari terakhir

2.3 Data Cleaning

Data yang memiliki nilai NaN atau Null akan dihapus

3.1 EDA (*Exploratory Data Analysis*)




Dari Correlation Heatmap, bisa didapat hubungan berikut:

- Hubungan positif kuat antara close_open_spread dan return_1d sebesar 0.79
- Hubungan terbalik antara volatilitas (high_low_spread) dengan performa pasar jangka menengah (return_30d) sebesar -0.56 dan tren jangka panjang (dist_sma_200) sebesar -0.64


Dari Histogram distribusi return_1d dan return_30d, bisa diambil hasil analisis berikut:

- Histogram return_1d berpusat ditengah, yaitu 0%, berarti harga saham lebih banyak stabil jika dibandingkan dengan hari sebelumnya
- Histogram return_30d lebih berpusat di 0.03-0.04, yaitu 3%-4%, berarti harga saham lebih banyak naiknya jika dibandingkan dengan 30 hari sebelumnya




Dari Histogram distribusi jarak dari indikator SMA 200, bisa diambil hasil analisis berikut:

- Distribusi tersebut dikatakan *skew* ke kiri, karena distribusinya lebih banyak di kanan
- Karena distribusi lebih banyak di kanan, maka saham lebih sering mengalami tren naik, daripada trend turun




Dari Line Chart Volatilitas harian, bisa diambil hasil analisis berikut:

- Bisa dilihat ada beberapa spike yang menandakan volatilitas perubahan harga yang tinggi, spike-spike ini sering bergerombol / berkumpul di masa-masa krisis, contohnya di 2008, 2011, dan 2020



Dual-Axis Chart dibawah juga mendukung hasil analisis diatas:

- Harga index (garis biru) menurun di masa-masa krisis contohnya 2008, 2011, dan 2020
- Karena harga index saham menurun, maka return (garis merah) juga akan menurun



Setelah melihat Correlation Heatmap di atas, bisa diteliti lebih lanjut tentang hubungan antar fitur dengan memetakan scatterplot antar setiap fitur seperti di bawah:

